

Research Proposal

Михаил Попов

AIRI, summer 2026

1 Статья:

CODEX: COunterfactual Deep learning for the in silico EXploration of cancer cell line perturbations

ссылка на статью:

https://academic.oup.com/bioinformatics/article/40/Supplement_1/i91/7700898

Ссылка на оригинальный репозиторий:

<https://github.com/sschrod/CODEX>

Статья была опубликована в рамках конференции Intelligent Systems for Molecular Biology (ISMB) в 2024 году.

2 Описание:

Статья посвящена задаче вычислительного предсказания последствий биологических perturbations: лекарственных воздействий, их комбинаций, а также генетических нокаутов или подавлений экспрессии. Задача *in silico* предсказания: по транскриптомным профилям и индексам возмущений (perturbagens) предсказывать, как клетка изменила бы свое состояние при новом воздействии.

Авторы предлагают метод CODEX — *COunterfactual Deep learning for the in silico EXploration of cancer cell line perturbations*. Ключевая идея CODEX состоит в использовании counterfactual-постановки. Модель получает описание исходного, непertурбированного состояния клетки или клеточной линии (X), информацию о примененном воздействии (T), а затем предсказывает downstream outcome (Y): например, drug response, synergy score или полный транскриптомный профиль после perturbation. В архитектуре CODEX сначала есть общий encoder, который переводит исходный профиль клетки в латентное представление. Затем это представление проходит через ветви, соответствующие отдельным perturbations. Если воздействие является комбинацией нескольких perturbations, активируются несколько ветвей, их эффекты агрегируются линейно, а затем общий decoder преобразует полученное латентное состояние в предсказание. Такая схема позволяет не

заводить отдельную ветвь для каждой комбинации, а значит, модель потенциально может обобщаться на новые комбинации воздействий.

Для моего проекта наиболее важна часть статьи, связанная с предсказанием транскриптомного профиля после генетических perturbations на датасете Norman et al. Этот датасет является Perturb-seq/CRISPRi single-cell dataset для клеточной линии K562. В нем измерены транскриптомные профили отдельных клеток после разных генетических вмешательств, включая одиночные и парные perturbations. Задача модели в этой постановке выглядит следующим образом: по контрольному профилю клетки и по информации о том, какие гены были подавлены, нужно восстановить экспрессию 5000 генов после perturbation. То есть target — это не один scalar score, а многомерный вектор экспрессии $(Y_i = (y_{i1}, \dots, y_{ip})), (p) - - -$.

Loss-функция формулируется как Gaussian negative log-likelihood: модель штрафует за отличие истинной экспрессии $(y_{ij}), .single - cell, ,$.

3 Выполненная работа:

Моя идея такова: так как по итогу качество работы модели оценивают при помощи сравнения экспериментально полученного и предсказанного наборов дифференциально экспрессированных генов (ДЭГ), то логичной идеей кажется добавить в обучение модели некоторое распределение приоритетов - то есть каждому гену сопоставить вес, чем сильнее он поменял свою экспрессию, тем важнее он для модели. Главное - рассчитывать ДЭГи только для train-выборки, иначе предсказывать нечего будет, если ДЭГи будут предпосчитаны для выборки test.

Чтобы учесть, насколько сильно ген поменял свою экспрессию, я использовал стандартные метрики, полученные экспериментально (log2FoldChange и adjpvalue). Формула для веса для гена:

$$w_{p,g} = 1 + \alpha \cdot \min \left(\frac{|\log_2 FC_{p,g}|}{L}, 1 \right) \cdot clip \left(\frac{-\log_{10} (p_{p,g}^{\text{adj}} + \varepsilon) - r_{\min}}{r_{\max} - r_{\min}}, 0, 1 \right) \quad (1)$$

$$clip(x, 0, 1) = \min(\max(x, 0), 1). \quad (2)$$

- $w_{p,g}$ — вес, назначаемый гену g для perturbation condition p .
- p — условие пертурбации, например single-gene knockout или double-gene knockout.
- g — индекс гена.
- α — коэффициент масштабирования, который задаёт максимальное дополнительное увеличение веса для сильно дифференциально экспрессированных генов. Так как score ограничен интервалом от 0 до 1, вес лежит в диапазоне $w_{p,g} \in [1, 1 + \alpha]$.

- $|\log_2 FC_{p,g}|$ — абсолютная величина эффекта для гена g при пертурбации p , без учёта направления изменения экспрессии.
- L — порог насыщения для абсолютного $\log_2$ fold change. Гены с $|\log_2 FC_{p,g}| \geq L$ получают максимальный вклад от компоненты effect size.
- $p_{p,g}^{\text{adj}}$ — скорректированное p -значение для дифференциальной экспрессии гена g при пертурбации p с поправкой на множественное тестирование.
- ε — малая положительная константа, добавляемая, чтобы избежать вычисления $\log_{10}(0)$.
- $r_{\min}$ — нижний порог значимости на шкале $-\log_{10}$ скорректированного p -значения. Гены со значимостью ниже этого порога получают малый или нулевой вклад от компоненты adjusted p -value.
- $r_{\max}$ — верхний порог значимости на шкале $-\log_{10}$ скорректированного p -значения. Гены со значимостью выше этого порога получают максимальный вклад от компоненты adjusted p -value.
- $\text{clip}(x, 0, 1)$ — функция, ограничивающая значение x интервалом $[0, 1]$:

Вес выглядит громоздко и сложно, однако он довольно интуитивный: учитывает кратность изменения уровня экспрессии геном, а также значимость этого изменения (в коде реализация проще - так как список генов сортирован по `adjrval`, рассчитываю этот коэффициент при помощи рангов генов).

Теперь учтем эти веса в функции потерь для их учета при обучении модели. Исходная функция потерь - Gaussian NLL:

$$\mathcal{L}_{i,g}^{\text{NLL}} = \frac{1}{2} \left[\frac{(x_{i,g} - \mu_{i,g})^2}{\sigma_{i,g}^2 + \varepsilon} + \log(\sigma_{i,g}^2 + \varepsilon) \right], \quad (3)$$

Предсказывает среднюю уровень экспрессии каждого гена и дисперсию этой величины.

Взвесим:

$$\mathcal{L}_i^{\text{weighted}} = \frac{\sum_{g=1}^G w_{p(i),g} \mathcal{L}_{i,g}^{\text{NLL}}}{\sum_{g=1}^G w_{p(i),g}}, \quad (4)$$

- i — индекс клетки в batch.
- g — индекс гена.
- $x_{i,g}$ — истинное значение экспрессии гена g в клетке i .
- $\mu_{i,g}$ — предсказанное моделью среднее значение экспрессии гена g в клетке i .

- $\sigma_{i,g}^2$ — предсказанная моделью дисперсия экспрессии гена g в клетке i .
- ε — малая положительная константа, добавляемая к дисперсии, чтобы избежать деления на ноль и вычисления логарифма от нуля.
- $p(i)$ — perturbation condition, соответствующая клетке i .
- $w_{p(i),g}$ — вес гена g для perturbation condition $p(i)$.

Весь код можно найти в репозитории GitHub:

https://github.com/PopovMD/AIRI_Summer2026_RP_CODEX/tree/main.